胚胎发育时间外推中细胞组成与表达变化的统计分析

NeurIPS 2026 Virtual Embryo Challenge T1 Temporal

小组成员：待填写（共四人） 日期：2026 年 10 月 17 日

1 问题背景与研究范围

胚胎发育伴随细胞分化、群体比例改变和基因表达重组。单细胞 RNA 测序能够观测不同发育阶段的表达状态，但分时采样缺少逐细胞的前后对应关系。已有研究使用最优传输分析时间快照并推断分化过程 [5]，也提示这类问题需要在模型假设下研究群体演化。

本组拟聚焦 Virtual Embryo Challenge 的 T1：根据较早阶段数据，预测未来阶段的一组细胞表达向量 [1]。预测目标是细胞群体的分布，包括状态组成及表达结构；本项目不将其解释为个体细胞的真实发育轨迹。研究重点是建立可解释的统计模型，比较其外推能力并分析失败原因。

2 具体研究问题

核心问题是：**在观测时间点有限的条件下，低维且受约束的外推能否改善未来细胞群体预测？**拟进一步研究：

（1） 降维与收缩能否减轻高维表达变化外推时的噪声放大?

（2） 调整细胞群体比例、调整群体内部表达分别带来哪些预测收益?

（3） 方法的表现是否随细胞群体、降维维数和外推强度发生变化?

以上均为待检验问题。主要工作定位为统一条件下的模型比较、消融与误差分析，结果将同时报告改善、退化及不稳定的情形。

3 数据来源与使用方案

使用官方发布的 T1 单细胞 RNA 数据。数据以 AnnData 文件组织，表达矩阵已作 log1p 归一化，包含 32,285 个基因及训练阶段的细胞类型注释 [2]。下载后将检查文件版本、矩阵含义、缺失值、基因顺序和注释一致性，避免重复归一化；特征处理和 PCA 仅在相应训练阶段上拟合。

角色	发育阶段	研究用途
初期训练	E8.5、E9.5	数据探索、表示学习与变化规则估计
开发验证	E10.5	按发布安排评价预测及选择模型
隐藏测试	E12.5	最终官方评价，真值不公开

T1 来自以心脏为中心的组织取样，阶段间取样范围与标签命名可能不同 [2]。分析中将先检查可比性，再解释群体比例或类别变化。本稿给出拟开展的研究设计，注册及数据获取状态由小组在提交前据实核实。

4 初步建模思路

参考基线。使用官方 `copy_last` 和 `pseudobulk_shift` 作为带引用的比较对象 [1]，分别代表沿用最近阶段的经验分布，以及依据已观察的平均表达变化进行整体平移。复现基线用于校验流程，本组分析围绕下述改进与受控比较展开。

低维收缩外推。设训练阶段为 $t_a < t_b$，在其数据上拟合 PCA，得到主成分基矩阵 $V_d \in \mathbb{R}^{p\times d}$。令 $\bar{\boldsymbol{x}}_a, \bar{\boldsymbol{x}}_b$ 为阶段平均表达。对最近阶段抽取的细胞 $\boldsymbol{x}_i(t_b)$，预测为

$$\widehat{\boldsymbol{x}}_i(t_\star) = \left[\boldsymbol{x}_i(t_b) + \alpha\frac{t_\star - t_b}{t_b - t_a} V_d V_d^\top (\bar{\boldsymbol{x}}_b - \bar{\boldsymbol{x}}_a)\right]_+, \tag{1}$$

其中 $\alpha \in [0,1]$ 控制变化幅度，$[\cdot]_+$ 表示逐元素非负截断。该方法在低维子空间估计趋势，并保留抽样细胞原有的高维残差；$\alpha = 0$ 对应最近阶段基线。将记录截断比例，检查约束处理对结果的影响。

分层扩展与消融。对标签能可靠对应、细胞数足够的群体，分别估计表达变化，并对群体比例作平滑、收缩及归一化后的保守调整。比较“均不调整”“仅调整表达”“仅调整比例”“同时调整”四种设置。样本少或缺乏对应的群体沿用最近阶段分布，并单独分析局限。该扩展取决于注释质量，优先保证基础模型能够完整运行。

主成分数与收缩强度仅设置少量候选值，保留全部比较记录。共同均值平移不能主动学习群体内部协方差演化，因此不预设平均表达改善一定带来结构指标改善。消融用于比较建模选择的经验作用，不作因果分解。

5 评价方案与泄漏防范

采用按时间留出的验证。先仅用 E8.5、E9.5 保存对 E10.5 的预测及配置；按照当前时间表，官方计划于 10 月 20 日公开验证真值 [3]。届时先评价冻结预测，再作有限模型选择，调参后的结果明确作为开发验证结果报告。同阶段随机拆分仅用于流程检查。

冻结方法与超参数后，按官方许可纳入已公开的 E10.5，并依据预定的最近两阶段变化率规则重新拟合，预测 E12.5。测试阶段的正式评分次数按规则使用，不根据评分反解任何目标信息 [4]。

主评价采用官方工具并固定版本，分别报告差异表达基因恢复（25%）、变化方向（25%）、细胞状态分布（30%）和基因共同变化结构（20%）[1]。提交文件按规定提供完整表达与基因顺序，主评价中的细胞类型由官方冻结分类器判定。

补充分析包括群体误差、代表性基因图和参数敏感性。各方法保持一致的预测细胞抽样预算，并用固定的若干随机种子重复抽样，描述算法和抽样波动；这些重复及大量细胞均不视为独立胚胎重复。

6 可能困难与应对

- **时间点少与新状态出现**。采用低自由度外推并分析失效群体；对未观察到的细胞状态保留预测局限，不声称恢复完整发育动力学。
- **取样与注释差异**。根据训练资料检查标签对应，必要时在可靠的较粗层级比较；不将所有阶段差异归因于分化。
- **高维计算与输出约束**。使用稀疏读取、适量抽样及低维计算；输出时核对非负性、有限值和官方基因顺序。
- **外部信息重叠**。初期仅使用官方允许的训练文件。后续若引入外部数据或预训练模型，将核查训练阶段、基因型与来源并完整披露，遵守 held-out data 规定 [4]。

7 进度安排与初步分工

10 月 18 日前完成开题及数据访问核实；至 11 月 19 日完成数据探索、基线和至少一种初步模型；11 月下旬完成主要消融与误差分析，并于 12 月 2 日前按规则完成至少一次有效官方提交；随后准备期末汇报，至 2027 年 1 月 5 日完成最终报告和复现材料。竞赛节点如有调整，以官方公告为准 [3]。

成员	初步职责
组员 A（待填）	数据获取、背景理解、预处理与探索分析
组员 B（待填）	参考基线、预测文件生成与官方提交流程
组员 C（待填）	低维外推、分层扩展与消融实验
组员 D（待填）	评价实现、稳健性检查与误差解释

全组共同核查方法、准备报告与答辩，并依据实际工作更新贡献。预期交付可复现的统一比较、消融与失败案例分析；即使改进未超过基线，也将据实解释适用条件和局限。

8 复现与 AI 辅助说明

代码拟包含 README、数据获取说明、主要分析与评价脚本、环境版本和随机种子，并记录官方工具版本、配置与预测文件。本开题讨论稿受到 ChatGPT ／ Codex 的资料核对、方案讨论及文字组织辅助；拟由组员主导方法设计与选择，核查引用、处理步骤和结果，并按实际工作方式遵守 Human Team ／ Agent Team 规则 [4]。

参考文献

[1] Virtual Embryo Challenge. Task 1 Temporal.

[2] Virtual Embryo Challenge. Data.

[3] Virtual Embryo Challenge. Timeline.

[4] Virtual Embryo Challenge. Official Rules.

[5] Schiebinger G, et al. Optimal-Transport Analysis of Single-Cell Gene Expression Identifies Developmental Trajectories in Reprogramming. *Cell*, 2019, 176: 928–943.e22. doi:10.1016/j.cell.2019.01.006.

官方网页核对日期：2026 年 10 月 17 日。