胚胎发育时间外推中细胞组成与表达变化的统计分析

NeurIPS 2026 Virtual Embryo Challenge T1 Temporal

小组成员：高景行　王恒毅　李凯瑞　崔帅达

日期：2026 年 10 月 18 日

1　问题背景与研究范围

胚胎发育伴随细胞分化、群体比例改变和基因表达重组。单细胞 RNA 测序能够观测不同发育阶段的表达状态，但分时采样缺少逐细胞的前后对应关系。已有研究使用最优传输分析时间快照并推断分化过程 [6]，也提示这类问题需要在模型假设下研究群体演化。

本组拟聚焦 Virtual Embryo Challenge 的 T1：根据较早阶段数据，预测未来阶段的一组细胞表达向量 [1]。预测目标是细胞群体的分布，包括状态组成及表达结构；本项目不将其解释为个体细胞的真实发育轨迹。研究重点是建立可解释的统计模型，比较其外推能力并分析失败原因。

2　具体研究问题

核心问题是：**在观测时间点有限的条件下，低维且受约束的外推能否改善未来细胞群体预测？** 拟进一步研究：

(1)　降维与收缩能否减轻高维表达变化外推时的噪声放大?
(2)　调整细胞群体比例、调整群体内部表达分别带来哪些预测收益?
(3)　方法的表现是否随细胞群体、降维维数和外推强度发生变化?

以上均为待检验问题。主要工作定位为统一条件下的模型比较、消融与误差分析，结果将同时报告改善、退化及不稳定的情形。

3　数据来源与使用方案

使用官方发布的 T1 单细胞 RNA 数据。数据以 AnnData 文件组织，表达矩阵已作 log1p 归一化，包含 32,285 个基因及训练阶段的细胞类型注释 [2]。下载后将检查文件版本、矩阵含义、缺失值、基因顺序和注释一致性，避免重复归一化；特征处理和 PCA 仅在相应训练阶段上拟合。

角色	发育阶段	研究用途
初期训练	E8.5、E9.5	数据探索、表示学习与变化规则估计
开发验证	E10.5	按发布安排评价预测及选择模型
隐藏测试	E12.5	最终官方评价，真值不公开

T1 来自以心脏为中心的组织取样，阶段间取样范围与标签命名可能不同 [2]，因此须先检查可比性，再解释群体变化。本组已完成官方平台团队注册，并确认可下载 `E8.5_RNA.h5ad`、`E9.5_RNA.h5ad`；数据内容将在获取后按上述流程校验。

4 初步建模思路

参考基线。复现官方 `copy_last` 和 `pseudobulk_shift`[1]，分别沿用最近阶段分布，以及按已观察的平均表达变化整体平移。另设**全基因空间收缩外推**：在下式中将 $V_dV_d^\top$ 替换为单位矩阵，保持时间倍率、收缩强度、截断和抽样一致，以区分降维与收缩的作用。

低维收缩外推。设训练阶段为 $t_a < t_b$，在其数据上拟合 PCA，得到基矩阵 $V_d \in \mathbb{R}^{p\times d}$。记阶段均值为 $\bar{\boldsymbol{x}}_a, \bar{\boldsymbol{x}}_b$，时间倍率 $h = (t_\star - t_b)/(t_b - t_a)$。对最近阶段抽取的细胞，预测为

$$\widehat{\boldsymbol{x}}_i(t_\star) = \left[\boldsymbol{x}_i(t_b) + \alpha h\, V_dV_d^\top(\bar{\boldsymbol{x}}_b - \bar{\boldsymbol{x}}_a)\right]_+, \tag{1}$$

其中 $\alpha \in [0,1]$ 为收缩强度，$[\cdot]_+$ 为逐元素非负截断；$\alpha = 0$ 对应最近阶段基线。模型保留抽样细胞的高维残差，并记录截断比例。PCA 可能遗漏时间变化方向，须与全空间收缩模型在相同 α 下比较。

分层扩展与消融。先依据训练资料确定可靠的共同标签或较粗分类；仅对两阶段各不少于 30 个细胞的匹配群体，在同一 PCA 基上估计群体内均值差。令 $\boldsymbol{\pi}_a, \boldsymbol{\pi}_b$ 为匹配集合内部的条件比例，按 $\widehat{\boldsymbol{\pi}} = \mathrm{Normalize}([\boldsymbol{\pi}_b + \beta h(\boldsymbol{\pi}_b - \boldsymbol{\pi}_a)]_+)$ 更新，$\beta \in [0,1]$，Normalize 表示除以分量之和。匹配集合的总质量及其他群体比例保持为最近阶段值，再按预测比例重抽样；未匹配或样本不足群体的表达也沿用最近阶段。若无合格群体则回退至整体模型。比较“均不调整”“仅调整表达”“仅调整比例”“同时调整”四种设置。

初设 $d \in \{10, 30, 50\}$，$\alpha, \beta \in \{0, 1/2, 1\}$，保留全部比较记录。共同均值平移不能主动学习群体内协方差演化；消融仅比较建模选择的经验作用，不作因果分解。

5 评价方案与泄漏防范

采用按时间划分的**开发验证**。官方计划于 10 月 20 日公开 E10.5 真值 [3]；公开后仅用 E8.5、E9.5 拟合预测模型，在 E10.5 上评价并作有限模型选择，保存配置、预测文件及 Git 版本。E10.5 参与调参，相关结果均标记为开发验证结果，不作为独立测试。同阶段随机拆分仅用于流程检查。

冻结方法、超参数和标签映射规则后，按官方许可用 E9.5、E10.5 重新拟合 PCA 与变化率，取 $h = 2$ 预测 E12.5。一步开发验证不能保证两天外推有效。正式提交前先做格式检查，并遵守测试阶段全阶段至多两次官方评分的现行限制，不根据评分反解目标信息 [4]。

主评价采用固定版本的官方工具，报告 DES（差异表达恢复，25%）、DCS（变化方向，25%）、MMD（细胞状态分布，30%）及 CSS（基因共同变化，20%）的原始值与官方总分；总分按官方 skill 校准后加权，不直接加权原始指标 [5]。提交完整表达并按目标 board 的基因清单排序；细胞类型由官方冻结分类器判定。

补充分析包括群体误差、代表性基因图和参数敏感性。各方法保持一致的预测细胞抽样预算，并用固定的若干随机种子重复抽样，描述算法和抽样波动。

6 可能困难与应对

- **时间点少与新状态出现**。采用低自由度外推并分析失效群体；对未观察到的细胞状态保留预测局限。
- **取样与注释差异**。根据训练资料检查标签对应，必要时在可靠的较粗层级比较。
- **高维计算与输出约束**。使用稀疏读取、适量抽样及低维计算；输出时核对非负性、有限值和官方基因顺序。
- **外部信息重叠**。初期仅使用官方允许的训练文件。后续若引入外部数据或预训练模型，将核查训练阶段、基因型与来源并完整披露，遵守 held-out data 规定 [4]。

7 进度安排与初步分工

已完成团队注册与训练数据下载和开题。10 月 20 日起开展开发验证，至 11 月 19 日完成数据探索、基线与初步模型；11 月下旬完成消融和误差分析，12 月 2 日前完成提交；随后准备汇报。以下为初步分工建议，后续按实际协作调整。

成员	学号	初步职责
高景行	2400010759	官网上数据获取、数据预处理与基本数据分析
王恒毅	2400010616	官网注册团队、参考 Baseline、预测文件生成与官方提交流程
李凯瑞	2400010604	做低维外推、分层扩展实验与消融实验
崔帅达	2400010883	评价实现代码与误差解释

全组共同核查方法、准备报告与答辩，并依据实际工作更新贡献。预期交付可复现的统一比较、消融与失败案例分析；即使改进未超过基线，也将据实解释适用条件和局限。

8 复现与 AI 辅助说明

代码拟包含 README、数据获取说明、分析与评价脚本、环境版本和随机种子，并记录官方工具版本、配置与预测文件。项目的想法有与 ChatGPT 的交流和讨论；文档基本由组员完成，部分用词用 ChatGPT 润色。拟按 Human Team 工作方式开展实验，组员讨论并选择方法、检查结果及决定调整。

参考文献

[1] Virtual Embryo Challenge. Task 1 Temporal.

[2] Virtual Embryo Challenge. Data.

[3] Virtual Embryo Challenge. Timeline.

[4] Virtual Embryo Challenge. Official Rules.

[5] Virtual Embryo Challenge. Task 1 Evaluation.

[6] Schiebinger G, et al. Optimal-Transport Analysis of Single-Cell Gene Expression Identifies Developmental Trajectories in Reprogramming. *Cell*, 2019, 176: 928–943.e22. doi:10.1016/j.cell.2019.01.006.